

COLDSTART - Prévoir et quantifier les crises sanitaires quand les données locales manquent

Candidature Ambizione FNS (dépôt : 3 novembre 2026) · Requérant : Dr Erol Orel
· Hôte : Institut de santé globale, Faculté de médecine, UNIGE · Durée : 4 ans

Le problème

Quand une crise sanitaire commence, les données locales nécessaires pour la prévoir n'existent pas encore. Les modèles les plus performants exigent plusieurs années d'historique ; ils sont donc les plus faibles exactement là où les décisions - armer des ambulances, ouvrir des lits, déclencher une escalade - sont les plus coûteuses et les moins réversibles.

Il existe pourtant une information quantitative disponible dès le premier jour : la littérature publiée sur des événements analogues - associations météo-demande, amplitudes et délais de surcharge, durées de séjour et occupation, paramètres de transmission. Elle n'est presque jamais utilisée comme information a priori formelle, parce que personne n'a établi si le faire aide ou nuit.

La question

Le projet pose la question de bout en bout : l'évidence publiée peut-elle être extraite de façon fiable et transportée au contexte local pour prévoir l'état du système de soins quand les données locales manquent ; peut-on détecter tôt quand elle induit en erreur ; le gain change-t-il des décisions opérationnelles ; et la chaîne complète peut-elle tourner automatiquement, vérifiée sur les issues observées, selon des règles pré-enregistrées ?

Le projet s'appuie sur un existant : LiteRev-Evidence, le prototype d'extraction et de modélisation en cours de développement ; la cartographie des données constituée pour GESICA ; et l'étude légionellose genevoise en cours (BASEC 2026-00324).

Cinq volets

1. **Extraction** - mesurer la fiabilité de l'extraction automatique de paramètres quantitatifs depuis la littérature, contre un étalon en double extraction humaine, et corriger les biais identifiés ; la littérature fournit aussi les variables explicatives, les familles de modèles recommandées et les définitions d'issues et de seuils.
2. **Modélisation** - représenter l'état du système de soins comme un processus à régimes latents (habituel / tendu / sous tension / critique) plutôt que comme un seuil appliqué à une prévision ponctuelle ; les modèles épidémiologiques (type SEIR) n'interviennent que pour les crises épidémiologiques, les crises environnementales relevant de structures exposition-réponse.
3. **Évaluation** - tester, épisode historique par épisode historique, si les a priori issus de la littérature améliorent la prévision en début de crise, en n'utilisant à chaque instant que les données et la littérature disponibles à cette date, avec sélection automatisée du meilleur modèle selon des règles pré-enregistrées.
4. **Décision** - évaluer non pas la précision statistique mais le bénéfice décisionnel, à partir de seuils d'escalade recueillis de façon structurée (protocole SHELF) auprès des régulateurs, urgentistes et gestionnaires de capacités.
5. **Automatisation et veille** - données publiques connectées automatiquement ; modèles relancés à la cadence de chaque variable ; hypothèses statistiques

vérifiées ; veille quotidienne de la littérature ; en fin de projet, pour les types d'événements validés et sous réserve d'autorisation, un tableau de bord quotidien en mode observation, enregistré et évalué prospectivement, jamais décisionnel pendant le projet.

Comment ce sera testé

Trois archétypes genevois, fixés pour toute la durée du projet : les **épidémies respiratoires** (SARS-CoV-2, grippe, VRS) portent le test confirmatoire ; la **canicule** (avec la pollution de l'air comme co-exposition) porte le test de généralisation, conduit seulement si le premier réussit ; la **légiionellose** genevoise est l'extension contrastante de quatrième année (incidence de cas). Deux bras - avec et sans évidence - passent par la même sélection automatisée pré-enregistrée ; la machinerie est d'abord validée de bout en bout sur des **données publiques ouvertes** (benchmark public), puis sur les séries opérationnelles genevoises.

Les données

Uniquement des **extraits rétrospectifs agrégés au jour** : aucun identifiant, aucune donnée individuelle, aucun enregistrement vocal, aucun texte libre. Le périmètre est le canton de Genève : données de régulation du 144 ; passages aux urgences et occupation des soins intensifs ; médecin et pharmacien cantonaux et SIG pour les volets environnementaux. Ainsi que toutes les autres données en accès libre (climatique, démographique, etc...). L'accès opérationnel passerait par la **voie officielle : une soumission à la CCER**.